



Marcar aula



Boas práticas

Módulo 37

Nesta seção você encontrará informações importantes que te ajudarão a aplicar efetivamente o que aprendeu

Compreender a importância da redução de dimensionalidade

A redução de dimensionalidade é crucial para simplificar a análise de dados, especialmente em contextos de alta dimensionalidade. Entender como a "maldição da dimensionalidade" pode afetar seus modelos é essencial para evitar sobreajustes e melhorar a eficiência computacional.

Implementar o PCA corretamente

Ao aplicar o PCA, siga as etapas fundamentais: padronização dos dados, cálculo da matriz de correlação ou covariância, seleção dos componentes principais e projeção dos dados nas novas dimensões. Isso garante que você está extraindo o máximo de informação possível dos dados.

Interpretação dos componentes principais

Após realizar o PCA, é importante interpretar os componentes principais para entender quais variáveis originais eles representam. Isso ajuda a manter a interpretabilidade dos dados reduzidos e a tomar decisões informadas.

Aplicação prática em projetos reais

Aplique o PCA em projetos reais para prever comportamentos ou intenções, como a intenção de compra em e-commerce. Isso não só reforça o aprendizado, mas também



Marcar aula



Exemplo de utilização no mercado de trabalho:

Análise de Dados Médicos: O PCA é usado para reduzir a dimensionalidade de dados médicos complexos, como exames de cardiograma, permitindo a identificação de padrões que podem indicar condições médicas específicas.

Previsão de Comportamento do Cliente: Em e-commerce, o PCA pode ser aplicado para reduzir a dimensionalidade de dados de clientes, ajudando a prever a intenção de compra e a personalizar ofertas.

Exemplo de código executável (em Python) que ilustra o PCA:

```
import numpy as np
import pandas as pd
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

# Exemplo: Dados fictícios de exames
data = np.array([[2.5, 2.4], [0.5, 0.7], [2.2, 2.9], [1.9, 2.2], [3.1, 3.0], [2.3, 2.7],
[2, 1.6], [1, 1.1], [1.5, 1.6], [1.1, 0.9]])

# Padronização dos dados
scaler = StandardScaler()
data_scaled = scaler.fit_transform(data)

# Aplicação do PCA
pca = PCA(n_components=1)
principal_components = pca.fit_transform(data_scaled)

# Exibindo os componentes principais
print("Componentes Principais:\n", principal_components)
```

Vamos discutir o código passo-a-passo:



Marcar aula



PCA : Inicializa o PCA para reduzir os dados a 1 componente principal.

fit_transform : Ajusta o modelo PCA aos dados padronizados e transforma os dados originais nos componentes principais.

Este exemplo demonstra como o PCA pode ser usado para simplificar dados bidimensionais em uma única dimensão, mantendo a maior parte da variabilidade original.

? **Tem dúvidas sobre esta lição? Faça uma pergunta a um tutor!**

Pergunte a um tutor

Ainda não há comentários

Adicionar primeiro comentário

Próximo:



De olho no erro



Marcar aula como concluída

Você gostou do conteúdo desta lição?





Marcar aula



WhatsApp

+55 (11) 4200-2991

Telefone

+55 (11) 4200-2991

Política de privacidade

Pt

Es

En

This site is protected by reCAPTCHA and the Google [Privacy Policy](#) and [Terms of Service](#) apply.